

From Zero-Shot to Fine-Tuning: Mengukur Domain Gap dan Peran Attention dalam Deteksi Helm Pengendara Motor

Tugas project: Visi Komputer Lanjut S2IF-48-01 [MDS]

Ardityo Cahyo
(203012510028)

Salman Rachmadi
(203012420009)

Ahmad Taufiq Nur Rohman
(203012420009)

Fakultas Informatika
Universitas Telkom, Bandung

Peta Perjalanan Eksperimen

01. Latar Belakang

Realita jalan raya & dua mitos populer industri.

02. Sanity Check

Menguji kemampuan model pretrained COCO.

03. Metodologi Eksperimen

Spesifikasi dataset Roboflow, 3 model & uji multi-seed.

04. Analisis & Uji Statistik

Hasil akurasi pasca fine-tuning & uji paired t-test.

05. Diskusi & Rekomendasi

Mengapa attention gagal & simpulan akhir.


Realita Jalan Raya & Solusi AI

Tantangan Pengawasan di Jalan Raya

- **Fatalitas Tinggi:** Sepeda motor mendominasi jalan raya, kepatuhan helm masih rendah.
- **Batas Manusia:** Pengawasan CCTV manual 24/7 tidak mungkin terskala karena kelelahan.

Solusi: Detektor AI Real-Time

- Pemantauan otomatis yang terskala untuk menindak pelanggaran lalu lintas.



Dua Mitos Populer di Deteksi AI

Mitos 1: Model Pretrained

"Model siap pakai (pretrained COCO) sudah cukup pintar mendeteksi helm tanpa perlu dilatih lagi."

Mitos 2: Asumsi Efek Instan Attention

"Menambahkan modul attention (CBAM / C2PSA) secara otomatis meningkatkan akurasi detektor."

Faktanya? Mari kita buktikan secara ilmiah.

Verifikasi Gap Domain: Model COCO Tanpa Fine-Tuning


Hasil Zero-Shot: Terbatas Secara Desain

- **Akurasi Rendah:** mAP hanya $\sim 10\%$ karena keterbatasan kelas pada model pretrained.
- **Tidak Mengenali Helm & Plat:** Bernilai 0,0% secara desain karena tidak ada di 80 kelas COCO.
- **Hanya Kelas Motorcyclist:** Dideteksi melalui pemetaan kelas *motorcycle* pada COCO.

Kesimpulan

Gap domain terlalu besar. **Fine-tuning wajib!**


Model Zero-Shot	mAP@0.5	helmet	plate
YOLOv8s	0,0986	0,000	0,000
YOLO11s	0,1143	0,000	0,000



Dampak Nyata Fine-Tuning

Zero-Shot
10%

Fine-Tuned
96%



Poin Utama: Adaptasi domain lokal jauh lebih krusial dibandingkan kompleksitas arsitektur model.

Dataset & Kelas Sasaran

Dataset: Roboflow NCKH

- **1.803 Gambar** ($1.563 / 140 / 100 = \text{Train/Val/Test}$) ≈ 8.229 instance.
- **Augmentasi ekspor:** rotasi $\pm 5^\circ$, shear $\pm 5^\circ$, kecerahan $\pm 20\%$, salt-and-pepper 5%.
- **Resolusi 1280px:** menangkap objek kecil (helm & plat) di kejauhan.
- Kondisi jalan raya luar ruangan yang realistis.

3 Kelas Target Deteksi

- license_plate: 42,5% (terbanyak).
- motorcyclist: 33,5%.
- helmet: 24,0% (paling sedikit & terkecil $\Rightarrow$ tersulit).

**Note:* Total 8.229 instance; ketidakseimbangan kelas alami.

Tiga Desain Model yang Diuji

Model	Jenis Attention	Parameter	Keterangan Arsitektur
YOLOv8s	None	~11,17 M	Baseline Klasik (Pure CNN)
YOLO11s	Parsial (C2PSA)	~9,40 M	Attention Bawaan (Generasi Baru)
YOLOv8s+CBAM	Eksternal (Channel & Spatial)	~11,51 M	Fokus pada fitur "what" & "where"

Perbandingan Adil

Jumlah parameter disetel setara ($\approx$ 9–11 Juta) agar perbandingan adil menilai efektivitas attention.

Posisi CBAM

Modul CBAM disisipkan pada bagian neck (P3/P4/P5) sebelum detektor objek.

Menjamin Validitas Eksperimen



Lingkungan Identik

GPU RTX 4090, hyperparameter, dan augmentasi data yang 100% seragam.



Multi-Seed ($n = 3$)

Dijalankan di 3 seed acak berbeda untuk mengeliminasi faktor kebetulan.




Uji Statistik Formal

Paired t-test untuk memvalidasi signifikansi perbedaan performa.

Hasil Akurasi Setelah Fine-Tuning

Model	mAP@0.5	mAP@[.5:.95]	FPS
YOLOv8s	$0,9596 \pm 0,0008$	$0,6885 \pm 0,0006$	~ 296
YOLO11s	$0,9574 \pm 0,0019$	$0,6902 \pm 0,0022$	~ 189
YOLOv8s+CBAM	$0,9481 \pm 0,0006$	$0,6832 \pm 0,0034$	~ 290

- **Akurasi Kasaran (mAP@0.5):** YOLOv8s murni memimpin dan paling cepat.
- **Presisi Lokalisasi (mAP@[.5:.95]):** YOLO11s (Attention) unggul tipis (+0,0017), namun lambat.
- **CBAM (Attention tambahan):** Justru mengalami penurunan performa.



Uji Signifikansi Statistik (Paired t-test)

Attention Tambahan (CBAM) Gagal

- **Turun Nyata:** Akurasi mAP@0.5 turun signifikan dibandingkan baseline ($p = 0,004$).
- Efek ukuran sangat besar (Cohen's $d = 9,3$).

YOLO11s vs YOLOv8s

- **Tidak Cukup Bukti Perbedaan:** Perbedaan tidak signifikan secara statistik ($p = 0,11$ untuk mAP@0.5, $p = 0,37$ untuk mAP@[.5:.95]).
- **Daya Statistik Rendah ($n = 3$):** Klaim kesetaraan definitif belum dapat diambil (*absence of evidence*).

Jawaban RQ2: Attention TIDAK memberikan keuntungan nyata.

Kecepatan Pengolahan & Deteksi Kualitatif

Kecepatan (FPS)

- **YOLOv8s**: ~ 296 FPS (Sangat cepat & efisien).
- **YOLO11s**: ~ 189 FPS (**36% lebih lambat** akibat komputasi attention C2PSA).

Kualitas Deteksi per-Kelas

- Pengendara & Plat Nomor terdeteksi di atas 96%.
- Kelas helm (objek kecil) mencapai 92,3%.



Deteksi YOLOv8s: Ketiga kelas terdeteksi secara akurat.

Diskusi Temuan: Mengapa Attention Kurang Efektif?

1. Efek Langit-langit (Ceiling)

Akurasi model baseline CNN murni (YOLOv8s) sudah terlampau tinggi (**95,9%**). Ruang peningkatan untuk modul attention sangat sempit pada dataset ini.

2. Gangguan Fitur (CBAM)

Inisialisasi acak modul CBAM pada model pretrained COCO mengganggu representasi fitur yang sudah matang, merusak akurasi tanpa proses pemanasan (*warmup*) yang lama.

**Catatan Keterbatasan:* Temuan negatif CBAM terbatas pada konfigurasi uji (P3/P4/P5, tanpa warmup terpisah, single learning rate) dan tidak berlaku umum untuk seluruh konfigurasi CBAM.

Kesimpulan & Rekomendasi

Kesimpulan Utama

- **Fine-Tuning Wajib:** Zero-shot COCO gagal mendeteksi helm.
- **CNN Murni Lebih Optimal:** YOLOv8s memberikan performa terbaik dan 36% lebih cepat daripada model ber-atensi.

Rekomendasi Praktis

- Gunakan **YOLOv8s** untuk CCTV/ETLE real-time.
- Uji model pada kondisi menantang (malam hari, oklusi parah, cuaca ekstrem).
- **Etika & Regulasi:** Integrasi pencatatan plat nomor otomatis memerlukan payung regulasi privasi data publik yang jelas.

Terima Kasih