

ProbPose: A Probabilistic Approach to 2D Human Pose Estimation

Paper Review — CVPR 2025
Miroslav Purkrabek & Jiri Matas

Ardityo Cahyo Salman Rachmadi Ahmad Taufiq

Paper Review: Purkrabek & Matas (CVPR 2025)


- 1 Apa itu Human Pose Estimation?
- 2 Bagaimana cara kerjanya? (Top-Down + Heatmap)
- 3 Masalah yang belum terselesaikan
- 4 ProbPose: Solusi probabilistik
- 5 Evaluasi baru: CropCOCO & Ex-OKS
- 6 Hasil eksperimen
- 7 Demo

Apa itu Human Pose Estimation?

Tujuan: Menemukan lokasi sendi-sendi tubuh manusia dalam gambar.


Output: 17 titik koordinat (x, y)

- Hidung, mata, telinga
- Bahu, siku, pergelangan tangan
- Pinggul, lutut, pergelangan kaki



17 keypoints (COCO)

Pendekatan Top-Down



- Deteksi orang → Crop per orang → Estimasi pose per orang
- Akurasi tinggi karena fokus satu orang per inferensi


Heatmap: Cara Model “Menunjuk” Lokasi Sendi

- Model output **17 peta** (satu per sendi)
- Setiap peta berukuran 64×48
- Nilai tinggi = “sendi kemungkinan di sini”
- Koordinat akhir = titik paling terang (argmax)

Training:

Target = Gaussian 2D di lokasi ground truth

Loss = MSE (Mean Squared Error)



Heatmap “lutut kiri”

Masalah 1: Keypoint di Luar Gambar




Figure 1: ProbPose (kiri) vs ViTPose (kanan)

Apa yang terjadi:

- Bounding box tidak selalu mencakup seluruh tubuh
- Beberapa sendi **terpotong**

Model konvensional:

- Tidak bisa bilang “tidak ada”
- Asal menebak lokasi → **salah**
- Evaluasi (OKS) **mengabaikan** masalah ini

ProbPose memprediksi kaki kanan di luar gambar dengan benar. ViTPose menempelkan kaki kanan ke kaki kiri.


Masalah 2: Heatmap Tidak Terkalibrasi

Heatmap konvensional:

- Nilai bukan probabilitas sesungguhnya
- Bentuk dipaksa Gaussian (sigma tetap)
- Tidak bisa mengekspresikan *ketidakpastian*

Dampak:

- Tidak bisa jawab: “seberapa yakin?”
- Berbahaya untuk aplikasi safety-critical
- Robot, self-driving, medis




Model konvensional hanya bisa bilang:

“Sendi ada DI SINI.”

ProbPose bisa bilang 4 hal:

1. Di mana sendi ini? (*Probability Map*)
2. Apakah sendi ini ada di gambar? (*Presence Score*)
3. Seberapa bagus tebakan saya? (*Quality Score*)
4. Apakah sendi terlihat atau terhalang? (*Visibility*)



Output 1: Probability Map


Heatmap konvensional:

- Setiap piksel independen
- Total bisa berapa saja
- Bukan probabilitas


Probability Map (ProbPose):

- Semua piksel **berbagi 100%**
- Total selalu = 1
- Probabilitas sesungguhnya
- Bentuk bebas (adaptif)

Heatmap (sum $\neq 1$)




Prob Map (sum = 1)



Output 2: Presence Score

“Apakah sendi ini **ada** di dalam gambar?”

Terlihat lengkap



Kaki terpotong



Threshold

< 0.5 : abaikan

≥ 0.5 : percaya

Model konvensional tidak punya kemampuan ini.

Output 3 & 4: Quality Score & Visibility

Quality Score:

“Seberapa bagus tebakan lokasi saya?”

- Self-assessment model
- Dit raining terhadap OKS sesungguhnya
- Terkalibrasi (angka bermakna)
- Berguna saat inferensi (tanpa ground truth)

Visibility:

“Apakah sendi terlihat atau terhalang?”

- Visible: terlihat langsung
- Occluded: ada tapi ketutupan
- Target dari anotasi COCO
- Berbeda dari presence (posisi vs halangan)

Presence: ada di gambar? **Quality:** tebakan bagus? **Visibility:** terlihat?

4 output → 4 loss function

Output	Loss	Target
Probability Map	OKS Heatmap Loss	OKS map
Presence Score	Binary Cross Entropy	0 atau 1
Quality Score	MSE	Skor OKS sesungguhnya
Visibility	Binary Cross Entropy	0 atau 1

$$\mathcal{L}_{total} = \mathcal{L}_{OKS} + \mathcal{L}_{presence} + \mathcal{L}_{quality} + \mathcal{L}_{visibility}$$

Semua head ditraining bersamaan, tapi hanya heatmap head yang melatih backbone.

Metrik evaluasi utama untuk pose estimation:

$$\text{OKS} = \exp\left(\frac{-d^2}{2 \cdot s^2 \cdot k^2}\right)$$

- d = jarak prediksi vs ground truth
- s = skala (ukuran orang)
- k = konstanta per keypoint

Nilai: 0 (salah total) $\rightarrow$ 1 (sempurna)

Toleransi berbeda per sendi:

Hidung	k kecil (ketat)
Bahu	k sedang
Pinggul	k besar (longgar)

Karena variasi antar-anotator manusia berbeda per sendi.

Expected OKS Maximization (Decoding)

Konvensional (argmax/UDP):

- Ambil titik tertinggi
- Refine lokal
- Bisa tertipu oleh spike tajam

ProbPose (Expected OKS):

- Hitung expected OKS per piksel
- Pilih yang memaksimalkan skor
- Lebih robust untuk distribusi bimodal




Figure 3: UDP decoding (kiri) vs Expected OKS maximization (kanan)

Masalah:


COCO biasa jarang punya keypoint di luar gambar
→ tidak bisa mengukur kemampuan model.

Solusi: CropCOCO


Gambar COCO di-crop lebih agresif sehingga banyak keypoint jatuh di luar frame.

Tujuan:

Mengukur kemampuan model menangani out-of-image keypoints.



Semua sendi di dalam



Kaki di luar frame

OKS biasa **mengabaikan** keypoint di luar gambar.
Ex-OKS **menghukum** false positive.

Situasi	OKS	Ex-OKS
KP di dalam + prediksi benar	skor tinggi	skor tinggi
KP di dalam + prediksi salah	skor rendah	skor rendah
KP di luar + model bilang “tidak ada”	diabaikan	skor tinggi
KP di luar + model bilang “ada”	diabaikan	skor rendah

Ex-OKS menghargai model yang jujur bilang “tidak tahu.”

Hasil: Perbandingan dengan SOTA

Semua model berukuran serupa. Evaluasi menggunakan GT bounding boxes.

Model	COCO		CropCOCO		OCHuman	
	mAP	Ex-mAP	mAP	Ex-mAP	mAP	Ex-mAP
ViTPose-s	75.9	75.3	72.7	66.5	60.3	60.1
HRFormer-s	75.2	74.6	70.9	64.3	60.3	60.0
SWIN-t	73.5	72.9	71.3	65.0	58.1	57.9
ProbPose-s	76.6	76.4	81.7	73.9	60.4	60.2

- COCO: peningkatan kecil (+0.7% vs ViTPose)
- **CropCOCO: peningkatan signifikan (+9.0%)** ← kontribusi utama
- OCHuman: kompetitif

Apa yang paling berkontribusi?


Prob. Map	Crop Aug.	COCO mAP	CropCOCO mAP
×	×	76.0	73.7
×	✓	76.4	72.4
✓	×	76.6	81.7
✓	✓	76.6	81.7

Temuan:

- Crop augmentation = kontributor utama untuk CropCOCO
- Probability map = keunggulan di versatility, bukan akurasi murni
- Kombinasi keduanya = hasil terbaik

Klasifikasi in/out-of-image:

- ProbPose presence probability mengurangi error **30–45%** dibanding confidence ViTPose
- Confidence tidak ditraining untuk tugas ini
- Threshold optimal: 0.15–0.4 (bukan 0.3 yang umum dipakai)




- ➊ **Peningkatan in-image kecil (+0.7% di COCO)**
Untuk kasus normal, manfaat minimal
- ➋ **Hanya model Small**
Belum diuji pada backbone besar (ViTPose-L, -H)
- ➌ **Multi-person belum dieksplorasi**
Crowded scene dengan banyak orang tumpang tindih
- ➍ **Bergantung pada crop augmentation**
Tanpa itu, probability map justru menurunkan performa
- ➎ **Anotasi COCO bermasalah di tepi**
Model dihukum karena lebih akurat dari ground truth

Kontribusi ProbPose:

- ① **Probability map** → distribusi terkalibrasi ($\text{sum}=1$)
- ② **Presence probability** → error turun 45%
- ③ **OXS-based loss** → training selaras dengan evaluasi
- ④ **CropCOCO + Ex-OXS** → evaluasi yang lebih lengkap
- ⑤ **Crop augmentation** → +9% di out-of-image

Pesan utama:

Pose estimation bukan hanya soal akurasi lokalisasi, tapi juga soal *kejujuran* model — tahu kapan harus bilang “tidak tahu.”



Stack yang digunakan:

Framework	MMPose (OpenMMLab)
Backbone	Vision Transformer Small (ViT-S)
Head	ProbMapHead (custom)
Input	256×192
Output	$64 \times 48 \times 17$ probability maps
Weights	ProbPose-s.pth (pre-trained)
Detector	YOLOX (untuk multi-person)

Kode tersedia di: github.com/MiraPurkrabek/ProbPose_code

Terima Kasih

Pertanyaan?

Paper: *ProbPose: A Probabilistic Approach to 2D Human Pose Estimation*

Purkrabek & Matas, CVPR 2025

arxiv.org/abs/2412.02254