

Perbandingan YOLOv8s, YOLO11s, dan YOLOv8s+CBAM untuk Deteksi Helm Pengendara Sepeda Motor

Laporan Tugas Proyek — Visual Komputer Lanjut

Ardityo Cahyo Salman Rachmadi Ahmad Taufiq

Fakultas Informatika
Universitas Telkom, Bandung


- ➊ Latar Belakang & Masalah
- ➋ Pertanyaan Riset & Hipotesis
- ➌ Metodologi (Dataset, Model, & Protokol Eksperimen)
- ➍ Hasil Eksperimen (Akurasi, Kecepatan, & Uji Statistik)
- ➎ Analisis & Pembahasan (Mengapa Atensi Gagal?)
- ➏ Kesimpulan & Saran

Pentingnya Deteksi Helm:

- Helm merupakan pelindung utama pengendara motor dari cedera kepala fatal dalam kecelakaan lalu lintas.
- Pemantauan kepatuhan secara manual oleh petugas tidak efisien dan tidak dapat diskalakan untuk volume lalu lintas nyata.
- Diperlukan otomatisasi berbasis **Computer Vision** (deteksi objek) menggunakan kamera CCTV jalan raya.

Masalah di Literatur:

- Banyak riset mengklaim menambahkan mekanisme atensi (misal: CBAM) meningkatkan akurasi deteksi helm.
- Namun, laporan tersebut seringkali mengabaikan pengujian statistik yang ketat (uji signifikansi) dan evaluasi multi-seed untuk mengontrol faktor kebetulan inisialisasi.



Pertanyaan Riset:

Apakah penambahan mekanisme atensi (seperti blok C2PSA pada YOLO11 atau modul CBAM pada YOLOv8) meningkatkan akurasi deteksi helm secara signifikan dalam kondisi pengujian multi-seed yang terkontrol?

Hipotesis Kerja:

- **YOLO11s** (memiliki blok *positional self-attention* C2PSA) sebagai arsitektur yang lebih baru akan menghasilkan akurasi (mAP) yang lebih tinggi dibandingkan baseline **YOLOv8s** (tanpa atensi).
- Penambahan modul **CBAM** (atensi saluran dan spasial) pada YOLOv8s akan meningkatkan akurasi lokalisasi kelas kecil (helm dan plat nomor).

Karakteristik Dataset:

- Menggunakan dataset publik Roboflow Universe: **NCKH 2023 Helmet Detection Project (v19)**.
- Total **1.803 gambar** dengan pembagian split tetap:
 - **Train:** 1.563 gambar
 - **Val:** 140 gambar
 - **Test:** 100 gambar (evaluasi akhir)
- Resolusi input ditingkatkan ke **1280 piksel** untuk mempertahankan detail spasial objek kecil.

3 Kelas Target Deteksi:

- 1 **motorcyclist:** Pengendara sepeda motor (sebagai konteks utama).
- 2 **helmet:** Helm yang digunakan (objek kepatuhan).
- 3 **license_plate:** Plat nomor kendaraan (sebagai jangkar identifikasi pelanggar).

Arsitektur Model yang Dibandingkan

Model	Jenis Atensi	Jumlah Parameter	Peran Eksperimen
YOLOv8s	None	~11,17 Juta	Baseline (Pure CNN)
YOLO11s	Partial (C2PSA)	~9,40 Juta	State-of-the-Art (Self-Attention)
YOLOv8s+CBAM	Channel + Spatial	~11,51 Juta	Intervensi Atensi Tambahan


- **YOLOv8s+CBAM** dibuat dengan menyisipkan 3 modul CBAM tepat sebelum kepala deteksi (skala P3, P4, P5) untuk meminimalkan perbedaan arsitektural di luar mekanisme atensi itu sendiri.
- Parameter bertambah $\sim 3\%$ dari baseline YOLOv8s.

- **Lingkungan:** Framework Ultralytics, PyTorch, GPU NVIDIA RTX 4090 tunggal.
- **Keadilan Hyperparameter:** Semua model menggunakan optimizer, augmentasi (mosaic, HSV, flip), resolusi input (1280), dan early stopping (patience=25) yang sama.
- **Kontrol Variabilitas (Multi-Seed):** Setiap model dilatih dan diuji sebanyak **3 kali** menggunakan seed yang berbeda (**Seed 42, 0, 1**).
- **Uji Signifikansi:** Melakukan **paired t-test** (uji-t berpasangan) pada performa mAP@0.5 antara baseline vs varian dengan $\alpha = 0,05$ untuk memvalidasi perbedaan nyata.

Performa Overall pada Split Test

Model	mAP@0.5	mAP@.5:.95	FPS
YOLOv8s	0.9592 ± 0.0014	0.6862 ± 0.0046	~ 296
YOLO11s	0.9569 ± 0.0046	0.6898 ± 0.0030	~ 189
YOLOv8s+CBAM	0.9479 ± 0.0004	0.6810 ± 0.0045	~ 290

- Metrik dilaporkan dalam bentuk **rata-rata $\pm$ standar deviasi** ($n = 3$).
- Baseline YOLOv8s mencatat mAP@0.5 tertinggi sekaligus kecepatan tercepat (~ 296 FPS).
- Penambahan CBAM menurunkan akurasi mAP@0.5 secara konsisten.



Hasil Uji Signifikansi Statistik (Paired t-test)


Perbandingan	Perbedaan Rata-rata (Δ)	$t(df)$	Nilai p	Cohen's d
YOLOv8s vs YOLO11s	-0,0023	0,73 (2)	0,54	0,61
YOLOv8s vs YOLOv8s+CBAM	-0,0113	10,9 (2)	0,008	9,1

- **YOLOv8s vs YOLO11s:** Perbedaan tidak signifikan ($p > 0,05$). Hipotesis bahwa YOLO11s lebih unggul **tidak terbukti**. Perubahan mAP berada dalam batas variasi acak inisialisasi.
- **YOLOv8s vs YOLOv8s+CBAM:** Terjadi penurunan akurasi yang **sangat signifikan secara statistik** ($p = 0,008$) dengan efek size yang sangat besar (Cohen's $d = 9,1$).

Analisis Performa Per-Kelas (YOLOv8s Baseline)


- motorcyclist: $\text{mAP@0.5} = \mathbf{0.990}$
 - Kelas termudah karena ukuran objek besar dan karakteristik visualnya sangat menonjol di frame.
- license_plate: $\text{mAP@0.5} = \mathbf{0.969}$
- helmet: $\text{mAP@0.5} = \mathbf{0.923}$
 - Kelas paling menantang karena ukuran helm kecil, variasi warna tinggi, dan rawan terhalang (oklusi).

Implikasi: Fokus pengembangan model deteksi helm ke depan harus diarahkan untuk mengatasi kelemahan pada kelas helmet.



Trade-off Akurasi vs Kecepatan (FPS)

- **YOLOv8s** mendominasi Pareto frontier dengan menjadi model terakurat sekaligus tercepat (~ 296 FPS).
- **YOLO11s** berjalan $\sim 36\%$ lebih lambat (~ 189 FPS) karena kompleksitas komputasi modul atensi C2PSA, tanpa memberikan peningkatan akurasi yang signifikan.
- **YOLOv8s+CBAM** mempertahankan kecepatan tinggi (~ 290 FPS) karena modul CBAM yang ringan, namun mengalami penurunan akurasi mAP@0.5 yang signifikan.





Analisis Deteksi Visual:

- Model berhasil mendeteksi ketiga kelas (motorcyclist, helmet, license_plate) secara simultan dengan koordinat kotak pembatas (*bounding box*) yang presisi.
- Analisis kualitatif pada sampel uji menunjukkan kesalahan lokalisasi mayoritas terjadi pada objek helm yang berukuran sangat kecil di kejauhan atau yang mengalami oklusi sebagian oleh pengendara lain.

Mengapa Mekanisme Atensi Gagal Meningkatkan Hasil?

❶ Efek Kejenuhan Dataset (Ceiling Effect):

- Akurasi baseline YOLOv8s sudah sangat tinggi ($\text{mAP@0.5} \sim 0.96$) pada dataset Roboflow yang relatif bersih ini.
- Dengan ruang sisa peningkatan yang sangat sempit, mekanisme atensi yang kompleks tidak memiliki cukup peluang untuk menunjukkan keunggulannya.

❷ Disrupsi Inisialisasi pada CBAM:

- Modul CBAM diinisialisasi secara acak, sedangkan bagian jaringan lainnya menggunakan bobot pratalah COCO (*pretrained COCO weights*).
- Dengan data latih yang terbatas (1.563 gambar), sinyal gradien tidak cukup kuat untuk menyelaraskan bobot baru CBAM dengan jalur fitur pretrained, mengganggu aliran fitur matang.

❸ Kompleksitas YOLO11s (C2PSA):

- Penambahan C2PSA tidak meningkatkan akurasi secara signifikan namun menurunkan FPS secara drastis, menunjukkan ketidakefisienan untuk dataset skala kecil-menengah.

Kesimpulan Utama:

- Hipotesis bahwa YOLO11s mengungguli YOLOv8s **tidak terbukti** secara statistik ($p = 0.54$).
- Penambahan modul CBAM justru **menurunkan akurasi secara signifikan** ($p = 0.008$) karena gangguan inisialisasi pada dataset kecil.
- **YOLOv8s murni** tetap menjadi model terbaik dari segi akurasi dan kecepatan untuk deteksi helm real-time.

Saran untuk Riset Selanjutnya:

- Evaluasi pada dataset jalan raya yang lebih menantang (kondisi hujan, malam hari, oklusi ekstrem).
- Lakukan **uji ablasi CBAM** yang lebih mendalam: penempatan di dalam backbone dan alokasi *learning rate* khusus untuk bagian atensi.
- Tambahkan jumlah seed pengujian (misal $n = 5$ atau 10) untuk memperkuat daya uji statistik pada perbedaan kecil.

Terima Kasih

Ada Pertanyaan?

Studi Perbandingan Keefektifan Mekanisme Atensi pada YOLO
Mata Kuliah Visual Komputer Lanjut